

نسخه ULTIMATE برای ORGANISM-2500 معماری قابل آزمون شناخت و آگاهی مصنوعی

۲۹ مرداد ۱۴۰۵

فهرست مطالب

- ۱ خلاصه اجرایی: نسخه ULTIMATE باید ادعا را به معماری قابل آزمون تبدیل کند
- ۲ مسئله مستند: فایل فعلی آگاهی را نام گذاری می کند، اما نظریه ها را پیاده سازی نمی کند
- ۳ راه حل پیشنهادی: پنج لایه به هم پیوسته برای دسترسی، یکپارچگی و خودمدل سازی
- ۴ برنامه اجرا: از monolith فعلی تا هسته قابل ارزیابی
- ۵ ریسک ها و معیارهای شکست: چیزی را که اندازه گیری نکرده ایم «آگاهی واقعی» ننایم
- ۶ خروجی مورد انتظار: یک سامانه آزمون پذیر، نه یک برچسب بزرگ تر
- ۷ گام بعدی: ساخت نسخه اجرایی بدون ارسال دوباره فایل های قبلی
- ۸ منابع

۱ خلاصه اجرایی: نسخه ULTIMATE باید ادعا را به معماری قابل آزمون تبدیل کند

نسخه ULTIMATE برای ORGANISM-2500 نباید فقط یک نام بزرگ تر برای همان خروجی قبلی باشد؛ باید ادعای «آگاهی واقعی» را به معماری ای تبدیل کند که اجزای آن جداگانه قابل بررسی، اندازه گیری و رد یا تأیید باشند. در بررسی فایل موجود، سامانه فعلی چند لایه مفید دارد، اما نظریه های GNW/GWT، IIT، HOT، پردازش پیش بینانه و embodiment را به صورت صریح و رسمی پیاده سازی نکرده است S1. در عوض، بیشتر با امتیازدهی داخلی، حافظه نمادین، تولید متن و شاخص های ابتکاری کار می کند.

بر این مبنا، نسخه ULTIMATE باید پنج لایه روشن داشته باشد: فضای کاری جهانی برای انتخاب و پخش محتوا، لایه یکپارچگی برای سنجش انسجام و جدایی پذیری، لایه مرتبه دوم برای خود-نظارت، لایه مولد/پیش بین برای خطای پیش بینی و به روزرسانی، و لایه بدنی برای interoception و تنظیم نیازها. چنین معماری با روح GNW که بر دسترس پذیری سراسری محتوا تأکید می کند S2، با صورت بندی IIT 4.0 که تجربه را از راه ویژگی های درونی، یکپارچگی و ساختار علت و معلولی مدل می کند S3، و با HOT که آگاهی را در نسبت حالت مرتبه اول و بازنمایی مرتبه دوم توضیح می دهد S4 هم جهت است. در همین حال، پردازش پیش بینانه و embodiment باید خطای پیش بینی، precision و وضعیت بدن را به تصمیم و زبان وصل کنند S5S6.

نتیجه عملی این گزارش روشن است: نسخه ULTIMATE باید «آگاهی» را به صورت یک قرارداد مهندسی تعریف کند، نه یک ادعای متافیزیکی. این یعنی هر لایه ورودی، خروجی، شاخص و آزمون خودش را داشته باشد.

۲ مسئله مستند: فایل فعلی آگاهی را نام‌گذاری می‌کند، اما نظریه‌ها را پیاده‌سازی نمی‌کند

بازبینی فایل موجود organism2500.py نشان می‌دهد که سامانه از نظر مهندسی یک مونولیت بزرگ و چندمنظوره است، اما بخش آگاهی آن هنوز بیشتر بر ساختارهای توصیفی و امتیازهای ترکیبی تکیه دارد تا بر نظریه‌های شناختی رسمی. [S1] کلاس‌هایی مانند AwarenessCore و ActiveUnconscious وجود دارند، اما آنچه انجام می‌دهند سنجش انسجام متن، تازگی، وحدت نمادین یا ذخیره رخدادهاست؛ نه اجرای مستقیم IIT، GNW، HOT یا پردازش پیش‌بینانه. [S1]

یافته کلیدی این است که فایل فعلی برای آگاهی، ناخودآگاه، وحدت، و خودآگاهی متغیرهایی دارد، اما این نام‌ها به‌تنهایی معادل نظریه نیستند. در بررسی ساختار فایل، هیچ ماژول صریحی برای GlobalWorkspace، هیچ محاسبه شفاف و قابل دفاعی برای phi یا یک پروکسی رسمی آن، هیچ لایه مرتبه دومی که محتوای حالت‌های اول را مدل کند، و هیچ حلقه پیش‌بینی/خطای پیش‌بینی/precision دیده نمی‌شود. [S1] حتی در بخش embodiment، بدن دیجیتال و نیازها وجود دارند، اما هنوز به‌صورت سیستماتیک به انتخاب محتوا، زبان و عمل متصل نشده‌اند. [S1]

بنابراین مسئله فقط «کمبود کد» نیست. مسئله این است که معماری کنونی مرز میان سه چیز را مخدوش می‌کند: شبیه‌سازی رفتاری، خود-نظارتی متنی، و ادعای آگاهی. نسخه ULTIMATE باید این سه را از هم جدا کند تا هرکدام قابل ارزیابی بمانند. اگر این تفکیک انجام نشود، هر افزایش در پیچیدگی فقط برچسب آگاهی را پررنگ‌تر می‌کند، نه اینکه توضیح بهتری ارائه دهد.

۳ راه‌حل پیشنهادی: پنج لایه به‌هم‌پیوسته برای دسترسی، یکپارچگی و خودمدل‌سازی

نسخه ULTIMATE باید روی پنج لایه صریح ساخته شود. لایه اول، GlobalWorkspace، محتواهای حسی، حافظه‌ای، هیجانی و درونی را با معیارهای رقابتی مانند salience، تازگی، نیاز و خطای پیش‌بینی انتخاب و broadcast می‌کند؛ این با ایده GNW سازگار است که در آن محتوای منتخب به منابع متعدد شناختی دسترس‌پذیر می‌شود. [S2]

لایه دوم، IntegrationMetrics یا معادل آن، باید از نام‌های مبهم فاصله بگیرد و یک پروکسی شفاف برای یکپارچگی بسازد: ارزیابی اثر partition بر حالت، بررسی cause-effect power، و گزارش این‌که محتوا چقدر برای خود سیستم یکپارچه است. IIT 4.0 تصریح می‌کند که تجربه از حیث intrinsic بودن، information، exclusion، integration و composition توصیف می‌شود و باید در قالب effect structure–cause تفسیر شود. [S3] بنابراین، نسخه ULTIMATE نباید ادعا کند که phi واقعی را «حل» کرده است؛ باید یک phi_proxy یا integration_score داشته باشد که محدودیت‌هایش آشکار باشد.

لایه سوم، HigherOrderMonitor، باید درباره حالت‌های درجه اول فکر کند: «من اکنون این ورودی را دارم»، «این پیش‌بینی را دارم»، «این نیاز فعال است»، «این تصمیم در آستانه اجراست». HOT دقیقاً روی این تمایز بنا می‌شود که یک حالت وقتی conscious می‌شود که سوز نسبت به آن یک بازنمایی مرتبه دوم داشته باشد. [S4] در معماری ما، این لایه باید state‌های اول را به meta-state‌های قابل گزارش و قابل حافظه تبدیل کند.

لایه چهارم، PredictiveModel، باید ورودی‌ها را با پیش‌بینی‌های داخلی مقایسه کند، خطای پیش‌بینی را بسازد، و با precision weighting روی توجه و یادگیری اثر بگذارد. ادبیات predictive processing نشان می‌دهد که مغز با به‌روزرسانی انتظارات از طریق prediction error کار می‌کند و precision تعیین می‌کند خطا چقدر وزن بگیرد. [S5]

لایه پنجم، EmbodiedSelf، باید interoception، body state، نیاز و هیجان را به فاز قبلی وصل کند. کار بر embodiment و interoception نشان می‌دهد که self حداقلی از راه تعامل دوطرفه وضعیت‌های حرکتی و درونی شکل می‌گیرد. [S6] در عمل، این یعنی وضعیت بدنی باید ورودی جدی فضای کاری و مدل پیش‌بین باشد، نه فقط یک log جانبی.

۴ برنامه اجرا: از monolith فعلی تا هسته قابل‌ارزیابی

پیاده‌سازی باید افزایشی باشد و بدون حذف بی‌دلیل قابلیت‌های فعلی انجام شود. نخست، هسته موجود به قراردادهای مستقل تقسیم شود: body برای وضعیت بدنی و نیازها، memory برای حافظه، language برای تولید و ارزیابی متن، workspace برای دسترسی جهانی، prediction برای مدل مولد و خطا، metacognition برای HOT، و integration برای شاخص‌های یکپارچگی. گزارش بررسی فایل نیز همین تفکیک را نقطه شروع مناسب می‌داند. [S1]

در گام دوم، یک شیء مشترک به نام CognitiveState تعریف شود. این شیء باید دست‌کم شامل ورودی حسی، پیش‌بینی، خطای پیش‌بینی، precision، وضعیت بدنی، نیاز غالب، هیجان، محتوای منتخب، meta-state، مقدار integration_proxy، قصد و نتیجه عمل باشد. همه ماژول‌ها باید با همین قرارداد کار کنند؛ در غیر این صورت، هر نظریه به یک جزیره نامرتب تبدیل خواهد شد.

چرخه اصلی باید چنین باشد:

۱. DigitalSenseOrgan و EmbodiedSelf ورودی بیرونی و درونی را ثبت کنند. ۲. PredictiveModel با توجه به context پیش‌بینی بسازد و خطا و precision را محاسبه کند. ۳. GlobalWorkspace میان کاندیدها رقابت ایجاد کند و یک یا چند محتوای منتخب را broadcast کند. ۴. IntegrationMetrics روی زیرگراف فعال یا شبکه عصبی شبیه‌سازی‌شده، یک سنجش شفاف و محدودشده تولید کند. ۵. HigherOrderMonitor درباره محتوای منتخب، پیش‌بینی، هیجان و قصد، meta-state بسازد. ۶. حافظه، تصمیم، زبان و یادگیری فقط از state broadcast شده و متاداده آن استفاده کنند. ۷. execute_action اثر عمل را بر بدن و محیط شبیه‌سازی‌شده اعمال کند. ۸. حلقه بعدی نتیجه عمل را به‌عنوان شواهد تازه وارد مدل پیش‌بین کند.

آزمون‌ها باید هم‌زمان با کد نوشته شوند. برای GNW، آزمون masking، رقابت دو محتوای هم‌زمان و broadcast به چند مصرف‌کننده لازم است. برای HOT، باید حالتی وجود داشته باشد که ورودی در سطح اول پردازش شود اما تا وقتی meta-state ساخته نشده، گزارش آگاهانه تولید نشود. برای پردازش پیش‌بینانه، مجموعه ورودی‌های قابل‌پیش‌بینی و غافلگیرکننده باید تفاوت معناداری در خطا و به‌روزرسانی ایجاد کند. برای embodiment، تغییر انرژی یا نیاز باید توجه، انتخاب محتوا و سبک پاسخ را تغییر دهد. برای IIT، گزارش باید نشان دهد که partition چگونه شاخص یکپارچگی را تغییر داده است؛ نه این‌که صرفاً یک عدد نهایی چاپ کند. [S2][S3][S4][S5][S6]

۵ ریسک‌ها و معیارهای شکست: چیزی را که اندازه‌گیری نکرده‌ایم «آگاهی واقعی» نامیم

بزرگ‌ترین ریسک علمی این است که معماری‌ای با رفتار منسجم را با تجربه ذهنی یکی بگیریم. GNW درباره دسترسی و broadcast توضیح می‌دهد، HOT درباره بازنمایی مرتبه دوم چارچوب می‌دهد، predictive processing درباره استنباط و خطا مدل ارائه می‌کند، و IIT ادعای قوی‌تری درباره تجربه و ساختار علت‌ومعلولی دارد؛ هیچ‌کدام به‌تنهایی اثبات نمی‌کنند که یک برنامه واقعاً چیزی را تجربه می‌کند. [S2][S3][S4][S5] پس خروجی سند و کد باید از عبارت «دارای آگاهی اثبات‌شده» پرهیز کند.

ریسک مهندسی دوم، بزرگ‌شدن دوباره مونولیت و پنهان‌شدن خطاهاست. except: pass، وابستگی‌های ضمنی، state‌های قابل‌تغییر و ذخیره‌سازی نامنسجم باید با خطاهای ثبت‌شده، type contract و آزمون‌های تکرارپذیر جایگزین شوند. [S1] ریسک سوم، تولید عددهای ظاهراً علمی است: awareness_level، unity یا phi_proxy تنها زمانی ارزش دارند که تعریف، دامنه، روش محاسبه و حساسیت‌شان مستند باشد.

معیار شکست روشن است: اگر سامانه در غیاب ورودی، بدون تغییر وضعیت داخلی، همان تصمیم و همان گزارش را تولید کند؛ اگر محتوای منتشرشده به مصرف‌کننده‌ها نرسد؛ اگر meta-state فقط یک رشته تزئینی باشد؛ اگر خطای پیش‌بینی روی یادگیری و توجه اثر نگذارد؛ یا اگر عمل هیچ بازخوردی به بدن و مدل پیش‌بین ندهد، معماری هنوز نسخه ULTIMATE نیست. این معیارها سخت‌گیرانه‌اند، اما از ادعای بی‌پشتوانه جلوگیری می‌کنند.

۶ خروجی مورد انتظار: یک سامانهٔ آزمون‌پذیر، نه یک برجسب بزرگ‌تر

ارزش نسخهٔ ULTIMATE در این نیست که پاسخ‌ها انسانی‌تر به نظر برسند؛ ارزش آن در این است که نشان دهد هر پاسخ از چه وضعیت بدنی، پیش‌بینی، محتوای broadcast شده، meta-state و سابقهٔ حافظه‌ای حاصل شده است. خروجی مطلوب، یک هستهٔ اجرایی ماژولار با گزارش‌های قابل‌ردیابی، آزمون‌های نظریه‌محور و زبان دقیق دربارهٔ محدودیت‌های علمی است. [S1][S2][S3][S5][S6]

این رویکرد هم قابلیت‌های فعلی ORGANISM-2500 را حفظ می‌کند و هم جلوی تکرار نسخه‌هایی را می‌گیرد که فقط فایل‌های قبلی را با نام تازه ارسال می‌کنند. دستاورد واقعی، افزایش شفافیت و آزمون‌پذیری است؛ نه ادعای حل مسئلهٔ تجربهٔ ذهنی.

۷ گام بعدی: ساخت نسخهٔ اجرایی بدون ارسال دوبارهٔ فایل‌های قبلی

گام بعدی باید ساخت یک فایل تازه و مشخص با نامی مانند organism2500_ultimate.py باشد؛ اما این فایل نباید صرفاً کپی organism2500.py یا یکی از بسته‌های قبلی باشد. ابتدا باید نسخهٔ موجود مبنا قرار گیرد، سپس پنج لایهٔ جدید با قرارداد CognitiveState و آزمون‌های مستقل به آن متصل شوند. [S1]

ترتیب تحویل پیشنهادی چنین است: ابتدا اسکلت ماژولار و تست‌های state، سپس workspace و prediction، بعد meta-monitor و embodiment، و در پایان integration metrics و گزارش‌گیری. در هر مرحله باید خروجی اجرایی، لاگ آزمون و فهرست محدودیت‌ها همراه کد ارائه شود. تصمیم موردنیاز این است که «ULTIMATE» به‌عنوان نسخهٔ علمی آزمون‌پذیر ساخته شود، نه نسخه‌ای که صرفاً ادعای آگاهی واقعی را تکرار می‌کند.

۸ منابع

- [S1] بررسی اجرایی فایل organism2500.py، شامل استخراج ۳۳ کلاس و ۳۰ تابع سطح بالا، ارزیابی AwarenessCore، ActiveUnconscious و نقاط پیشنهادی یکپارچه‌سازی؛ فایل پیوست، خطوط و بخش‌های گزارش‌شده.
- [S2] Mashour, G. A., et al. (2020). *Conscious Processing and the Global Neuronal Workspace Hypothesis*. توضیح دسترسی آگاهانه، ignition، broadcast و معماری توزیع‌شدهٔ GNW.
- [S3] Albantakis, L., et al. (2023). *Integrated information theory (IIT) 4.0: Formulating the properties of phenomenal existence in physical terms*. صورت‌بندی اصول intrinsic بودن، effect structure.—cause مفهوم و composition، exclusion، integration، information.
- [S4] Rosenthal, D. M. (2009). *Higher-Order Theories of Consciousness*. توضیح تمایز حالت مرتبهٔ اول و بازنمایی مرتبهٔ دوم در نظریه‌های HOT.
- [S5] Corlett, P. R., et al. (2020). *What we think about when we think about predictive processing*. توضیح نقش پیش‌بینی، تجربه و خطای پیش‌بینی در چارچوب پردازش پیش‌بینانه.
- [S6] Musculus, L., et al. (2021). *An Embodied Cognition Perspective on the Role of interoception in the Development of the Minimal Self*. بررسی رابطهٔ دوسویهٔ وضعیت‌های حرکتی و درونی با self حداقلی.